


第二章 词法分析



第二章 词法分析



词法分析: $x := y + z * 60.0 ;$
 $id1 := id2 + id3 * 60.0 ;$

词法的双重含义:

1. 规定单词形成的规则, 也被称为构词规则或词法规则。它的作用相当于立法, 规定什么样的输入序列是语言所允许的合法单词。
2. 根据构词规则识别输入序列, 也被称为词法分析。它的作用相当于执法, 根据规则识别出合法的单词和指出非法的输入序列。

本章主要内容:

1. 与词法分析有关的基本概念和相关问题
2. 模式的形式化描述—正规式
3. 记号的识别—有限自动机 (NFA, DFA)
4. 词法分析器的构造—从正规式到DFA



2.1 词法分析中的若干问题

2.1.1 记号、模式与单词

单词的基本分类:

关键字 (保留字)	kw(key word, or reserved word)
标识符	id(identifier)
字面量	literal
特殊符号	ks(key symbol, or special symbol)

例2.1 语句 position := initial + rate * 60
 id ks id ks id ks number

注意: 称识别出id而不是rate或initial

问题: 根据什么识别这些词法的基本单位 (词法元素)?



三个术语:

模式 (pattern) : 产生和识别元素的规则

记号 (token) : 按照某个模式 (或规则) 识别出的元素 (一组)

单词 (lexeme) : 被识别出的元素自身的值 (一个), 也称为词值

记号的类别	单词举例	模式的非形式化描述
const(01)	const	const
if(03)	if	if
relation(81)	<, <=, =, <>, >, >=	<或<=或=或<>或>或>=
id(82)	pi, count, D2	字母打头的字母数字串
num(83)	3.1416, 0, 6.02E23	任何数值常数
literal(84)	“core dumped”	双引号之间的任意字符串
Comment	{x is an integer}	括号之间的任意字符串



记号的属性

记号是按照某个模式识别出的元素。

再考察赋值句 $\text{position} := \text{initial} + \text{rate} * 60$

position 、 initial 和 rate 均为标识符，即它们的种类均是id。

问题：当识别出一个id时，如何判定是哪个id？

同样，当识别出一个relations时，究竟是 $=$ 还是 $<$ ？

记号 = 记号的类别 + 记号的属性

例2.2 表达式 $\text{mycount} > 25$ 由三个记号组成

类别	82	81	83
----	----	----	----

属性	mycount	5	25
----	------------------	---	----

注意： <1> 5与25的区别

(根据记号的类别)

<2> 25与“25”的区别

(如何区别?)

记号的类别

单词举例

记号的非形式化描述

relation(81) $<, <=, =, <>, >, >=$

id(82) $\text{pi}, \text{count}, \text{D2}$

num(83) 3.1416, 0, 6.02E23

$<$ 或 $<=$ 或 $=$ 或 $<>$ 或 $>$ 或 $>=$

字母打头的字母数字串

任何数值常数



2.1.2 词法分析器的功能与工作方式

特征： 编译器中唯一与源程序打交道的部分

任务：

- <1> 识别记号并将其转为内部编码形式，交给语法分析器。
- <2> 删除无用的空白符、回车符以及无用的非实质性字符。
- <3> 删除注释。
- <4> 进行词法检查，报告所发现的错误。



工作方式：



<1> 单独一遍扫描

<2> 作为语法分析器的子程序

<3> 并行方式





2.2 模式的形式化描述

2.2.1 字符串与语言

从词法分析的角度看程序设计语言，它是由记号组成的集合。

从本章开始，我们用定义的方式表示一些重要的概念，目的是希望同学们深刻理解并牢固记忆这些基本概念。由于不同的教材（或出版物）对相同的概念有不同的称谓，因此希望同学们掌握概念的实质，而不是死记几个名词术语。

定义2.1 语言 L 是有限字母表 Σ 上有限长度字符串的集合。 ■

字母表是组成字符串的所有字符的集合。换句话说，字符串中的所有字符取自字母表。

定义中强调两个有限，因为计算机的表示能力有限：

<1> 字母表是有限的，即字母表中元素是有限多个；

<2> 字符串的长度是有限的，即字符串中字符个数是有限多个。



字母表是符号的非空有穷集合。任何语言都有自己的字母表。

例如，Pascal语言的字母表为

$\Sigma = \{A \sim Z, a \sim z, 0 \sim 9, +, -, *, /, <, =, >, :, ', ", ;, .., \uparrow, (,), \{, \}, [,]\}$

字符串：由字母表中的符号组成的任意有穷序列。

字符串的长度：字符串中的符号个数。

[例]字母表 $\Sigma = \{a, b, c\}$ ，则其上的语言 $L = \{\varepsilon, a, b, c, aa, ab, ac, ba, bb, bc, \dots\}$ ，还有其他的吗？

由于字符串的有序性，使得以字符串作为元素的集合，与一般意义上的集合有所不同，反映在集合运算上，强调了有序。



字符串的基本概念

表示、术语

举例

$|S|$

$|abc| = 3$

ε

$|\varepsilon| = 0$

$S1S2$

“abc”“def”=“abcdef”

S^n (幂)

“abc”³ = “abcabcabc”

S 的前缀 X

“abc”的前缀可以是: ε , a, ab, abc

S 的后缀 X

“abc”的后缀可以是: ε , c, bc, abc

S 的子串 X

“abc”的子串可以是: ε , a, b, c, ...

S 的真前缀、

“abc”的真前缀可以是: a, ab

真后缀、

?

真子串

?

S 的子序列 X

“abdf”是“abcdef”的一个子序列 (S 中去掉0或若干个不一定连续的字符后形成的字符串)

S 的逆转 S^R

$S=abc, S^R=cba$



字符串集合的运算

表示、术语 意义

Φ 空集合，即元素个数为0的集合

$\{\varepsilon\}$ 空串作为唯一元素的集合

$X=L \cup M$ X 是集合 L 和 M 的并: $X=\{s \mid s \in L \text{ or } s \in M\}$

$X=L \cap M$ X 是集合 L 和 M 的交: $X=\{s \mid s \in L \text{ and } s \in M\}$

$X=LM$ X 是集合 L 和 M 的连接: $X=\{st \mid s \in L \text{ and } t \in M\}$

$X=L^0$ $L^0=\{\varepsilon\}$, L 为任意字符串集合

$X=L^*$ X 是集合 L 的Kleene闭包: $X=L^0 \cup L^1 \cup L^2 \cup \dots$

$X=L^+$ X 是集合 L 的正闭包: $X=L^1 \cup L^2 \cup L^3 \cup \dots$

若 $L=\{a, b\}$, $M=\{c, d\}$

则 $LM=\{ac, bc, ad, bd\}$ (而 $L \cap M=\Phi$)

$L^*=\{\varepsilon, a, b, aa, bb, ab, ba, aaa, \dots\}$

$L^+=\{a, b, aa, bb, ab, ba, aaa, \dots\}$



2.2.2 正规式与正规集

定义2.2 令 Σ 是一个有限字母表, 则 Σ 上的正规式 r 及其表示的集合 $L(r)$ 递归定义如下:

1. ε 是 Σ 上的正规式, 它表示集合 $L(\varepsilon) = \{\varepsilon\}$ 。
2. 若 a 是 Σ 上的字符, 则 a 是正规式, 它表示集合 $L(a) = \{a\}$ 。
3. 若正规式 r 和 s 分别表示集合 $L(r)$ 和 $L(s)$, 则
 - (a) $r|s$ 是正规式, 表示集合 $L(r) \cup L(s)$,
 - (b) rs 是正规式, 表示集合 $L(r)L(s)$,
 - (c) r^* 是正规式, 表示集合 $(L(r))^*$,
 - (d) (r) 是正规式, 表示的集合仍然是 $L(r)$ 。(加括弧改变优先级、结合性)

可用正规式描述的语言称为正规语言或正规集。 ■



<1> 运算的优先级与结合性

若正规式的优先级和结合性做下述约定：

1. 三种运算均具有左结合性质；

2. 优先级从**高到低**顺序排列为：闭包运算、连接运算、或运算。

则正规式中不必要的括号可以被省略。

例如， $(a) | (((b)^*) (c))$ 可以简化成 $a | b^*c$ 。

<2> 正规式的等价

不同正规式也可以表示同一个正规集，即正规式与正规集之间是多对一的关系。



定义2.3 若正规式P和Q表示了同一个正规集，则称P和Q是等价的，记为 $P=Q$ 。 ■

例2.3 设字母表 $\Sigma=\{a, b, c\}$ ，则 Σ 上部分正规式和正规集如下：

正规式	对应正规集
-----	-------

a, b, c	$\{a\}, \{b\}, \{c\}$
-----------	-----------------------

$a b, b a$	$\{a\} \cup \{b\} = \{a, b\}$
------------	-------------------------------

$a(a b)^*$	$\{a, aa, ab, aba, abb, aab, \dots\}$, a为首的ab字符串
------------	---

Σ^*	$\{\varepsilon, a, b, c, aa, ab, ac, ba, bb, bc, abc, \dots\}$
------------	--

例2.4 令 $L(x)=\{a, b\}$, $L(y)=\{c, d\}$,

则 $L(x|y)=\{a, b, c, d\}$

$L(y|x)=\{a, b, c, d\}$



<3> 正规式等价的判定 (证明)

利用正规式的等价性可以化简复杂的正规式。正规式的等价性判定可以采用两种方法:

- 根据定义, 证明不同的正规式表示同一集合 (例2.4)
- 根据下述正规式的代数性质进行运算

正规式的代数性质 (表2.4)

$$r|s = s|r$$

$$(rs)t = r(st)$$

$$r|(s|t) = (r|s)|t$$

$$\varepsilon r = r\varepsilon = r$$

$$r(s|t) = rs|rt$$

$$r^* = (r+|\varepsilon) \text{ (} r+ \text{的定义见后)}$$

$$(s|t)r = sr|tr$$

$$r^{**} = r^*$$



2.2.3 记号的说明

正规式可以严格地规定记号的模式，用正规式说明记号的公式为：

记号 = 正规式

可以读作为 “（左边）记号被定义为（右边）正规式”，

或者 “记号是正规式”

例如 $id = a(a|b)^*$ 可以读作为 “id被定义为 $a(a|b)^*$ ”

通常在不引起混淆的情况下，也把说明记号的公式简称为正规式，或者规则。



例2.5 记号relation、id和num分别是Pascal的关系运算符、标识符和无符号数，它们的正规式表示如下所示。

relation = < | <= | <> | > | >= | =

id = (a|b|c|d|e|f|g|h|i|j|k|l|m|n|o|p|q|r|s|t|u|v|w|x|y|z
 |A|B|C|D|E|F|G|H|I|J|K|L|M|N|O|P|Q|R|S|T|U|V|W|X|Y|Z)
 (a|b|c|d|e|f|g|h|i|j|k|l|m|n|o|p|q|r|s|t|u|v|w|x|y|z
 |A|B|C|D|E|F|G|H|I|J|K|L|M|N|O|P|Q|R|S|T|U|V|W|X|Y|Z
 |0|1|2|3|4|5|6|7|8|9)*

num = (0|1|2|3|4|5|6|7|8|9) (0|1|2|3|4|5|6|7|8|9)*
 (ε | . (0|1|2|3|4|5|6|7|8|9) (0|1|2|3|4|5|6|7|8|9)*)
 (ε | E(+|-|ε) (0|1|2|3|4|5|6|7|8|9) (0|1|2|3|4|5|6|7|8|9)*)



<1> 简化正规式描述

(a) **正闭包** 若 r 是表示 $L(r)$ 的正规式, 则 r^+ 是表示 $(L(r))^+$ 的正规式, 且下述等式成立:

$$r^+ = rr^* = r^*r, \quad r^* = r^+ | \varepsilon$$

$+$ 与 $*$ 具有相同的运算结合性和优先级

例如: $(0|1|2|3|4|5|6|7|8|9)(0|1|2|3|4|5|6|7|8|9)^*$

可以化简为: $(0|1|2|3|4|5|6|7|8|9)^+$

(b) **可缺省** 若 r 是正规式, 则 $r^?$ 是表示 $L(r) \cup \{\varepsilon\}$ 的正规式, 且下述等式成立:

$$r^? = r | \varepsilon$$

$?$ 也可以与 $*$ 具有相同的运算结合性和优先级

注意: 引入算符 $?$ 的主要目的是为了回避不可以直接通过键盘输入的字符 ε 。

例如: $E(+|-|\varepsilon)$ 可以改写为: $E(+|-)^?$

(c) 字符组 若 r 是仅由 $|$ 运算构成的正规式，则可改写为 $[r']$ ，其中 r' 可以有如下两种形式：（注：这里的 r' 不是正规式）

枚举：如 $[abc]$ ，它等价于： $a|b|c$

分段：如 $[0-9a-z]$ ，

它等价于： $[0123456789abcdefghijklmnopqrstuvwxyz]$

(d) 非字符组 若 $[r]$ 是一个字符组形式的正规式，则 $[\hat{r}]$ 是表示 $\Sigma - L([r])$ 的正规式。

例如：若 $\Sigma = \{a, b, c, d, e, f, g\}$ ，

则 $L([\hat{abc}]) = \{d, e, f, g\}$

<2> 引入辅助定义

辅助定义的形式与用正规式说明记号的格式一样，因为它本身也是一个正规式，但它不与任何模式匹配。

换句话说，作为辅助定义的正规式仅供内部使用，而不予说明记号（辅助定义不是词法规则）。



例2.6 引入正规式的缩写形式和辅助定义式后，id和num的正规式定义可重写如下。

char = [a-zA-Z]

digit = [0-9]

digits = digit⁺

optional_fraction = (. digits)?

optional_exponent = (E (+|-)? digits)?

id = char (char|digit)*

num = digits optional_fraction optional_exponent

对比：

id = (a|b|c|d|e|f|g|h|i|j|k|l|m|n|o|p|q|r|s|t|u|v|w|x|y|z
|A|B|C|D|E|F|G|H|I|J|K|L|M|N|O|P|Q|R|S|T|U|V|W|X|Y|Z)
(a|b|c|d|e|f|g|h|i|j|k|l|m|n|o|p|q|r|s|t|u|v|w|x|y|z
|A|B|C|D|E|F|G|H|I|J|K|L|M|N|O|P|Q|R|S|T|U|V|W|X|Y|Z
|0|1|2|3|4|5|6|7|8|9)*

num = (0|1|2|3|4|5|6|7|8|9) (0|1|2|3|4|5|6|7|8|9)*
(ε |. (0|1|2|3|4|5|6|7|8|9) (0|1|2|3|4|5|6|7|8|9)*)
(ε |E(+|-| ε) (0|1|2|3|4|5|6|7|8|9) (0|1|2|3|4|5|6|7|8|9)*)