


第二章 词法分析



第二章 词法分析



词法分析: $x := y + z * 60.0 ;$
 $id1 := id2 + id3 * 60.0 ;$

词法的双重含义:

1. 规定单词形成的规则, 也被称为构词规则或词法规则。它的作用相当于立法, 规定什么样的输入序列是语言所允许的合法单词。
2. 根据构词规则识别输入序列, 也被称为词法分析。它的作用相当于执法, 根据规则识别出合法的单词和指出非法的输入序列。

本章主要内容:

1. 与词法分析有关的基本概念和相关问题
2. 模式的形式化描述—正规式
3. 记号的识别—有限自动机 (NFA, DFA)
4. 词法分析器的构造—从正规式到DFA



2.3 记号的识别—有限自动机

模式的描述—正规式

记号的识别—有限自动机（确定、不确定）

2.3.1 不确定的有限自动机

(Nondeterministic Finite Automaton, NFA)

定义2.4 NFA是一个五元组 (5-tuple) :


$M = (S, \Sigma, \text{move}, s_0, F)$, 其中

- (1) S 是有限个状态 (state) 的集合;
- (2) Σ 是有限个输入字符 (包括 ε) 的集合;
- (3) move 是一个状态转移关系, $\text{move}(s_i, \text{ch})=s_j$ 表示, 当前状态 s_i 下若遇到输入字符 ch , 则转移到状态 s_j ;
- (4) s_0 是唯一的初态 (也称开始状态);
- (5) F 是终态集 (也称接受状态集), 它是 S 的子集, 包含了所有的终态。 ■



<1> 直观表示方式

① 状态转换图：用一个有向图来直观表示NFA。



NFA中的每个状态，对应转换图中的一个节点；

NFA中的每个 $\text{move}(s_i, a) = s_j$ ，对应转换图中的一条有向边；
它表示从 s_i 节点出发，进入 s_j 节点，字符 a （或 ε ）是边上的标记。

② 状态转换矩阵：用一个二维数组来直观表示NFA。

矩阵中，一个状态对应一行，一个字符对应一列；

每个矩阵元素 $M[s_i, a]$ 中的内容，是从状态 s_i 出发，经字符 a （或 ε ）所到达的下一状态 s_j 的集合；

在转换矩阵中，一般以矩阵第一行所对应的状态为初态，
而终态需要特别指出。

	...	a
i		j




例2.7 识别正规式 $(a|b)^*abb$ 所描述正规集的NFA的三种表示形式分别如下。(其中, 转换矩阵表示中0为初态, 3为终态)

按定义: $S = \{0, 1, 2, 3\}$, $\Sigma = \{a, b\}$ $s_0 = 0$, $F = \{3\}$

$move = \{ move(0, a) = 0, move(0, a) = 1,$ 按状态转换矩阵:

按状态转换图:



$move(0, b) = 0, move(1, b) = 2,$
 $move(2, b) = 3\}$

	a	b
0	{0, 1}	{0}
1	—	{2}
2	—	{3}
3	—	—

<2> 记号在NFA中的表现 (NFA如何识别记号)

对字符串, 从初态开始, 经一系列状态转移到达终态。

例如: 对于字符串abb, 有

定义: $move(0, a) = 1, move(1, b) = 2, move(2, b) = 3$

转换矩阵: $m[0, a] = \{0, 1\}, m[1, b] = 2, m[2, b] = 3$


转换图: $0 \underline{a} 1 \underline{b} 2 \underline{b} 3$

显然, 转换图最直观, 即每一个记号, 实质上是从初态开始到某个终态的路径上的标记。



例2.8 识别表2.1中记号relation、id和num的转换图

relation = < | <= | <> | > | >= | =




id = char(char|digit)*





```
optional_fraction = ( . digits )?  
optional_exponent = ( E (+|-)? digits )?  
num = digits  
    optional_fraction  
    optional_exponent
```





正规式: $(a|b)^*abb$

按定义:


$S = \{0, 1, 2, 3\}$, $\Sigma = \{a, b\}$ $s_0 = 0$, $F = \{3\}$

$\text{move} = \{ \text{move}(0, a) = 0, \text{move}(0, a) = 1,$
 $\text{move}(0, b) = 0, \text{move}(1, b) = 2,$
 $\text{move}(2, b) = 3 \}$

按状态转换矩阵:

	a	b
0	{0, 1}	{0}
1	—	{2}
2	—	{3}
3	—	—

按状态转换图:



0是初态, 3是终态



<3> NFA (识别记号) 的特点

NFA识别记号的最大特点是它的不确定性, 即在当前状态下对同一字符有多于一个的下一状态转移。

<4> 不确定性的表现

- 定义: move是1对多的;
- 转换图: 同一状态有多于一条边标记相同字符但转移到不同的状态;
- 转换矩阵: $M[s_i, a]$ 是一个状态的集合。




<5> NFA识别输入序列的一般方法



反复试探所有路径，直到到达终态，或者到达不了终态。

<6> 不确定性识别记号的困惑

识别输入序列时，在当前状态下遇到同一字符，应转移到哪个下一状态？


例2.9 在正规式 $(a|b)^*abb$ 的NFA上识别输入序列abb和abab；

abb:  非终态，不接受，试探下一路径

 终态，接受 → 

abab: 







<7> NFA识别记号存在的问题

1. 只有尝试了全部可能的路径，才能确定一个输入序列不被接受，而这些路径的条数随着路径长度的增长成指数增长。
2. 识别过程中需要进行大量回溯，时间复杂度升高且算法趋于复杂。

问题：

是否可以构造这样的有限自动机，它识别正规式所描述的字符串，且在任何一个状态下遇到**同一字符**最多有一个状态转移？



2.3.2 确定的有限自动机

(Deterministic Finite Automaton, DFA)

定义2.5 DFA是NFA的一个特例，其中：

- (1) 没有状态具有 ε 状态转移 (ε -transition)，即状态转换图中没有标记 ε 的边；
- (2) 对每个状态 s 和每个字符 a ，最多有一个下一状态。



与NFA相比，DFA的特征（确定性）

定义： $\text{move}(s_i, a)$ 是一个状态转移函数；

转换图： 从一个节点出发的边上标记 均不相同；

转换矩阵： $M[s_i, a]$ 是一个 状态。

且字母表不包括 ε 。



对NFA施加两条限制：


限制1：没有 ϵ 状态转移

限制2：同一状态下没有重复字符的状态转移


例2.10 正规式 $(a|b)^*abb$ 的DFA和识别输入序列abb和abab：

识别abb：0a1b2b3，状态，接受

识别abab：0a1b2a1b2，？



	a	b
0	1	0
1	1	2
2	1	3
3	1	0





将在DFA上识别输入序列的过程形式化为算法，该算法被称为模拟器（模拟DFA的行为）或驱动器（用DFA的数据驱动分析动作）。

算法与DFA一起，即构成识别记号的词法分析器的核心。它的最大特点是算法与模式无关，仅DFA与模式相关。



算法2.1 模拟DFA

输入 DFA D 和输入字符串 x (eof)。 D 的初态为 s_0 ，终态集为 F 。

输出 若 D 接受 x ，回答“yes”，否则回答“no”。

方法 用下述过程识别 x ：


```
s:=s0;  ch:=nextchar;      -- 初值
while  ch≠eof                -- 循环
loop    s:=move(s, ch);  ch:=nextchar;
end      loop;
if      s is in F          -- 返回
then return “yes”; else return “no”;
end if;
```

用算法2.1识别abb:

1. $s=0$, $ch=a$
2. $s=1$, $ch=b$
3. $s=2$, $ch=b$
4. $s=3$, $ch=eof$
5. yes

用算法2.1识别abab:

1. $s=0$, $ch=a$
2. $s=1$, $ch=b$
3. $s=2$, $ch=a$
4. $s=1$, $ch=b$
5. $s=2$, $ch=eof$
6. no






2.3.3 有限自动机的等价

定义2.6 若有限自动机 M 和 M' 识别同一正规集，则称 M 和 M' 是等价的，记为 $M=M'$ 。 ■

特别提示：

正规式与有限自动机从两个侧面表示正规集。正规式是描述，自动机是识别。

因此，当它们表示相同集合时，均存在等价的问题。



想一想，有几种可能的等价？